

Mark2 阿里实验对应报告

按照《AI RAN博弈共识.pdf》逐点对应真实轨迹、代码与结果

报告项目	内容
实验性质	阿里 GenTD26 真实生产轨迹驱动 + 明确假设映射
场景	峰值小时 2024-12-06 00:00:00，抽取 N=100 个成功请求
代码	01_源码与说明/仿真代码_mark2_alibaba.py
主要结果	PSNE K=74；总代价=208.1783
诊断全局最优	K=57；总代价=178.5765

结论边界

本报告将原文框架逐点对应到数据、代码和实际输出。最佳响应收敛到纯策略纳什均衡（PSNE）不等于系统总代价全局最优；报告不会把均衡收敛表述为全局最优。

原始框架来源：01_源码与说明/原始模型_AI_RAN博弈共识.pdf

1 原文框架与实验实现总览

原文位置	数学/算法内容	本实验实现	输出证据
1.1 网络场景	N 个节点； $s_i \in \{0,1\}$ ； $K = \sum s_i$	100 个玩家；0 本地，1 卸载	equilibrium_strategy_s_star.csv
1.2 代价函数	能耗 + 算力拥塞 + 内存惩罚	分别构造本地、卸载及共享拥塞代价	parameters*.json；输入 CSV
1.3 势博弈	$\Delta C_i = \Delta \Phi$ ；有限改进收敛到 PSNE	记录每轮 Φ 并逐节点检查 PSNE	convergence_trace.csv；run_summary.json
Algorithm 1	随机异步最佳响应	随机抽取节点并严格改善更新	代码 best_response；收敛曲线
3.1 Baselines	All-Local / All-Offload / Random / Greedy	四类基准 + 诊断全局最优	algorithm_comparison.csv
3.2 指标 1	收敛性与稳定性	势函数、更新次数、PSNE 检验	convergence.*
3.2 指标 2	系统总代价	归一化系统总代价比较	algorithm_comparison.*
3.2 指标 3	Memory Violation Rate	容量压力/敏感性重复试验	memory_violation_sweep.*
3.2 指标 4	LLM 协调开销	仅数值协调器；未调用 LLM	llm_coordination_overhead.csv

2 原文 1.1：网络场景与真实请求映射

项目	使用的数据	代码位置	生成结果
N	峰值小时 435 个成功请求中固定种子抽取 100 个	第 51-60 行	trace_input_sample.csv
玩家 i	每个玩家对应一个真实匿名请求	第 179-186 行	node=0..99
s_i	0 本地；1 卸载	第 109-139 行	equilibrium_strategy_s_star.csv
K(s)	每轮由 s.sum() 计算	第 99-107、123-126 行	convergence_trace.csv

Mark2 Alibaba: equilibrium strategy s^*




图 1 | 真实请求异质性下的 s^* 。74 个请求卸载，26 个映射为本地执行。

3 原文 1.2：数据驱动代价函数

Mark2 保持“本地基础代价 vs 卸载基础代价 + 共享拥塞”的势博弈结构，但使用阿里轨迹校准任务与拥塞。

组成	真实数据/假设	具体值或字段	代码位置
云端执行	真实请求	exec_time_seconds；以样本中位数归一化	第 83-84 行
传输代价	假设映射	tx_base=0.15；prompt_weight=0.15	第 85-87 行
本地代价	假设映射	local_slowdown=1.8；addition=0.4	第 88 行
队列拥塞	真实统计校准	queue median=203.0ms；P95=451.0ms	第 62-69、89-96 行
推理基准	真实统计	inference median=35049.5ms	第 63、69、89 行
容量	假设	capacity_fraction=0.8，即 K_cap=80	第 38、91 行
内存惩罚	假设	alpha=1.2；beta=8.0	第 93-97 行

字段名带 _trace 的数据直接来自阿里轨迹；带 _assumed_mapped 的字段是模型映射结果。GPU 显存分位数用于报告校准背景，但没有被错误当作逐请求显存增量。

4 原文 1.3 与 Algorithm 1：势函数和最佳响应

环节	代码位置	输出	结果
共享拥塞	第 93-97 行	shared_congestion_cost	队列统计 + 指数容量惩罚
势函数	第 99-103 行	convergence_trace.csv	改变时严格下降
最佳响应	第 120-139 行	changed、k_offload	836 次更新、80 次改变
全节点 PSNE 检查	第 109-118、127-132 行	converged_to_psne	true
诊断全局最优	第 141-149 行	social_optimum_diagnostic	K=57；非算法保证

Mark2 修正了原伪代码的停止判据漏洞：连续 N

次随机抽取无变化可能重复抽到同一节点，所以停止前还要逐节点检查是否存在可改善偏离。




图 2 | 阿里真实请求与拥塞统计校准后，势函数仍沿严格改善路径下降并到达 PSNE。

5 原文 3.1 与指标二：基准和系统总代价

算法	K	系统总代价	是否 PSNE
best_response_psne	74.00	208.1783	1.00
all_local	0.00	255.0000	0.00
all_offload	100.00	1030.6029	0.00
random_p_0.5_mean	50.09	202.7327	0.00
greedy_trace_base_only	100.00	1030.6029	0.00
social_optimum_diagnostic	57.00	178.5765	0.00

基准生成：第 167-177 行。系统总代价：第 104-107 行。结果：algorithm_comparison.csv。Random 是 500 个随机状态均值，不是稳定策略。




图 3 | 轨迹驱动总代价比较。PSNE/诊断全局最优=1.17；PSNE 仍不等于全局最优。

6 原文 3.2 指标三：Memory Violation Rate

Mark2 将容量从 $K=50$ 扫描到 $K=95$ ，每个容量点重复 100 次。代码第 189-199 行；输出 memory_violation_sweep.csv。违规判定为 $K > K_{\text{capacity}}$ 。




图 4 | 容量敏感性。最佳响应在本次假设扫描中没有违规；Greedy 始终违规。容量 K 是请求等价槽位假设，不是阿里直接提供的物理 GPU 容量。

真实数据中 GPU 显存中位数约 24.82 GB、P95 约 33.57 GB，但这些是容器级使用量，不能直接解释为逐请求 v_i 。

7 原文 3.2 指标四：LLM 协调开销

输出字段	Mark2 值	解释
coordinator	numeric_trace_driven_proxy	Python 数值协调器
coordination_calls	836	异步协调次数
strategy_changes	80	实际策略改变次数
llm_model	not_used	未调用真实 LLM
Token / latency	not_measured	没有真实 Prompt、API、推理或网络通信

对应代码第 206-208 行；输出 llm_coordination_overhead.csv。真实阿里数据改善了任务与云端拥塞真实性，但没有自动加入边缘-中心通信或 LLM 推理步骤。

8 文件索引

类别	文件
真实输入样本	02_表格数据/trace_input_sample.csv
参数与校准	02_表格数据/parameters_and_calibration.json
策略	02_表格数据/equilibrium_strategy_s_star.csv
收敛	02_表格数据/convergence_trace.csv
算法比较	02_表格数据/algorithm_comparison.csv
容量测试	02_表格数据/memory_violation_sweep.csv
LLM 开销	02_表格数据/llm_coordination_overhead.csv
运行摘要	02_表格数据/run_summary.json
结果图	03_结果图/PNG、PDF、SVG、TIFF
源码	01_源码与说明/仿真代码_mark2_alibaba.py
官方数据说明	01_源码与说明/阿里GenAI2026_官方数据说明.md